



Construyendo Redes de Neuronas Convolucionales (CNN)

Moisés Martínez



About me

PhD in Computer Science and AI

Big Data & AI Architect

Researcher on different universities



Universidad
Carlos III de Madrid

T3chFest and GDG Cloud Madrid Organizer

GDE in Machine Learning

Moisés Martínez




@moisipm



@momartinm

Herramientas

Despliegue



Desarrollo



Tecnologías ML



TensorFlow



TensorBoard

1. Machine Learning

1. Machine Learning

- Definición de Aprendizaje RAE

Adquirir el conocimiento de algo por medio del estudio o de la experiencia.



1. Machine Learning

- Definición de Aprendizaje RAE

Adquirir el conocimiento de algo por medio del estudio o de la experiencia.

- Definición de Aprendizaje Automático

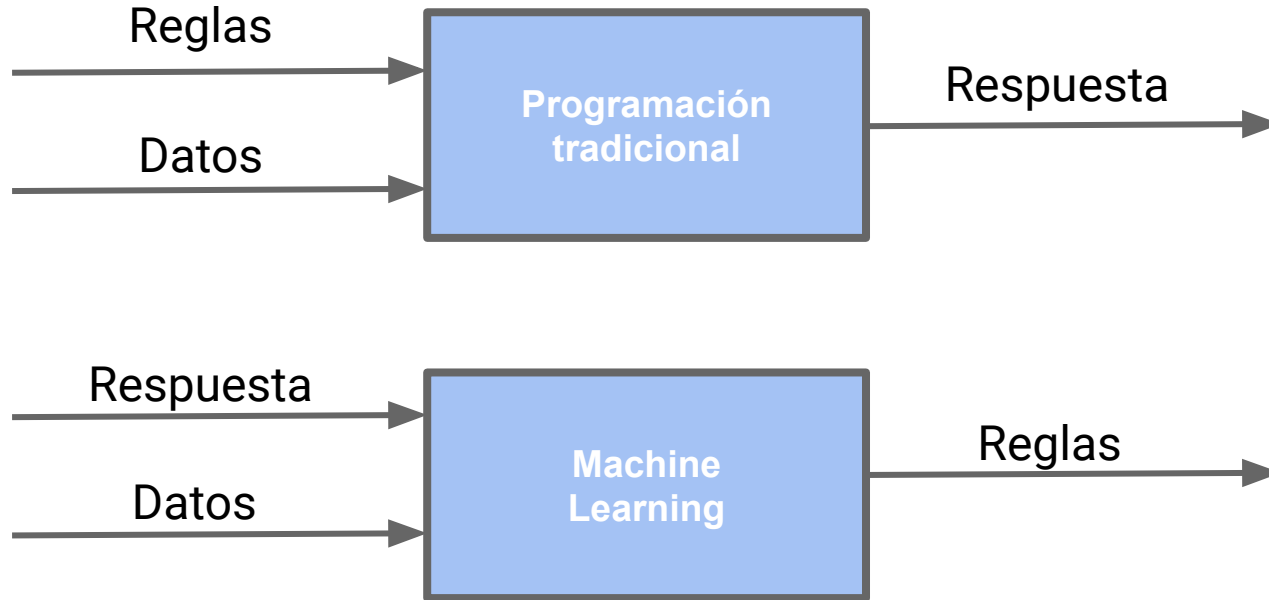
Proceso de **adquisición** de conocimiento de manera **automática** mediante la utilización de **ejemplos** (**experiencia**) de entrenamiento



1. Machine Learning




1. Machine Learning



1. Machine Learning


Supervisado



Datos + Respuestas

Ejemplos + Labels


No Supervisado



Datos

Ejemplos

Por Refuerzo



Respuestas^{Refuerzo} + Datos


Acciones^{Refuerzo} + Estados

Identificar Patrones

Definir políticas

1. Machine Learning

Supervisado




Datos + Respuestas

Ejemplos + Labels

Identificar Patrones


No Supervisado



Datos

Ejemplos

Por Refuerzo




Respuestas^{Refuerzo} + Datos

Acciones^{Refuerzo} + Estados

Definir políticas

1. Machine Learning


Supervisado



Datos + Respuestas
Ejemplos + Etiquetas


Identificar Patrones

No Supervisado



Datos
Ejemplos

Por Refuerzo



Respuestas^{Refuerzo} + Datos
Acciones^{Refuerzo} + Estados

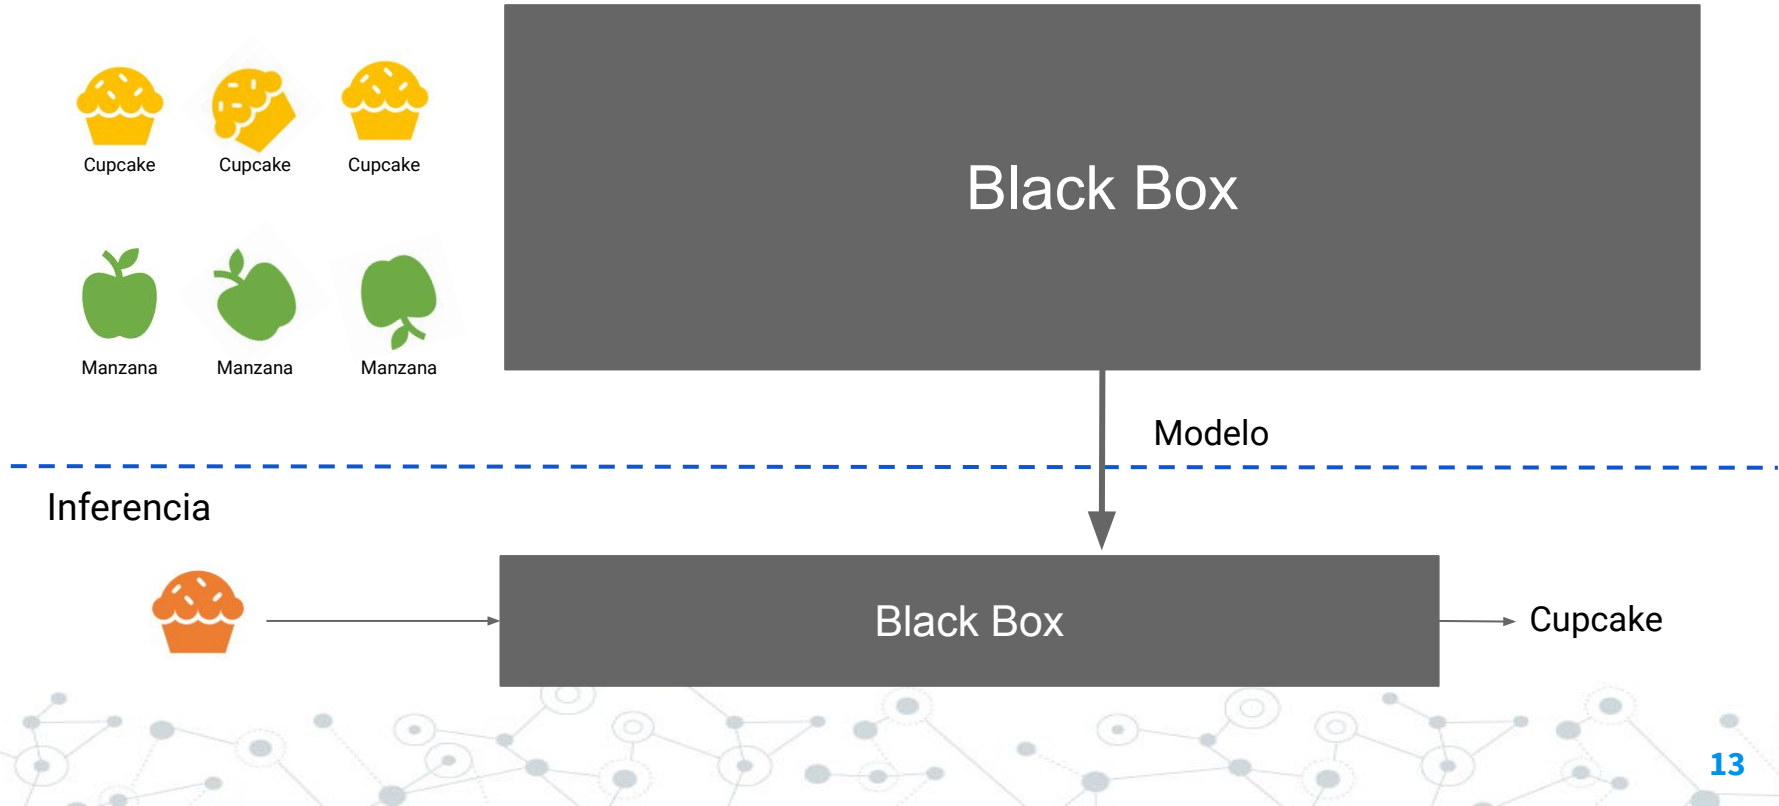
Definir políticas

Ejemplos de aprendizaje **etiquetados previamente** (Conocemos la clases)

2. El proceso de aprendizaje

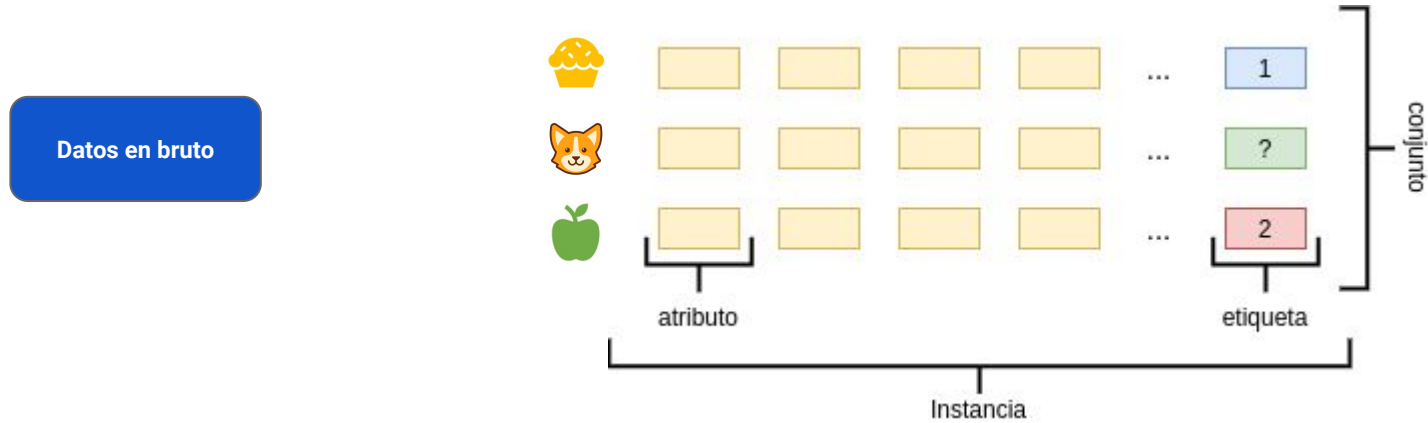
2. El proceso de aprendizaje

Entrenamiento



2. El proceso de aprendizaje


Entrenamiento



Instancia: Estructura básica para representar la información. Está compuesta por una secuencia de **atributos** que describen cada uno de los ejemplos.

2. El proceso de aprendizaje

Entrenamiento

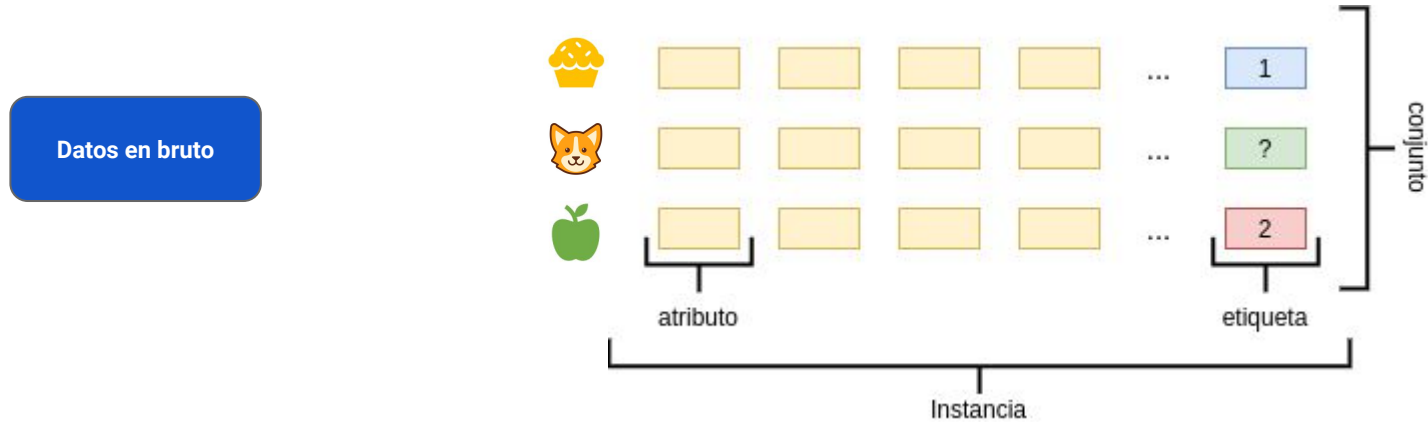


Atributo: Unidad básica para almacenar y describir la información. Suele almacenarse de dos formas:

- Continuo: Son valores numéricos de tipo continuo

2. El proceso de aprendizaje

Entrenamiento

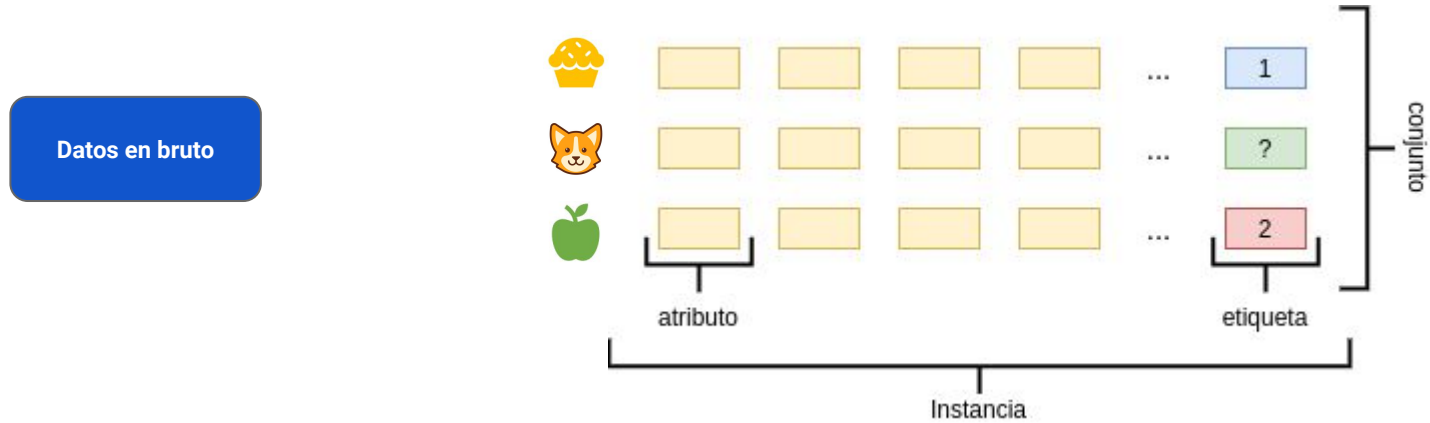


Atributo: Unidad básica para almacenar y describir la información. Suele almacenarse de dos formas:

- Continuo: Son valores numéricos de tipo continuo
- Discreto: Son valores de cualquier estructura (Cadenas de caracteres, números, etc)

2. El proceso de aprendizaje

Entrenamiento

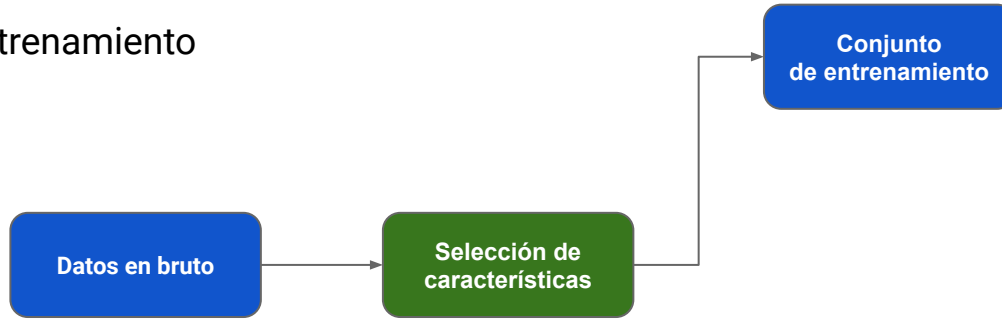


Objetivo: Es el valor esperado para cada una de la instancias. Tiene múltiples denominaciones:

- Clase
- Etiqueta
- Valor a predecir (Numérico)

2. El proceso de aprendizaje

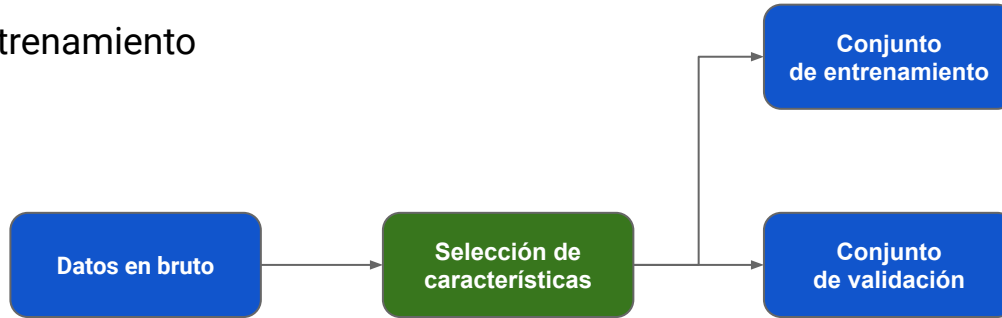
Entrenamiento



Conjunto de entrenamiento: Es un conjunto de instancias que son utilizadas para el proceso de entrenamiento con el objetivo de construir un modelo.

2. El proceso de aprendizaje


Entrenamiento



Conjunto de validación: Es un conjunto de instancias que son utilizadas para comprobar la calidad del modelo construido durante el proceso de entrenamiento

2. El proceso de aprendizaje


Entrenamiento



Conjunto de test: Es un conjunto de instancias que son utilizadas para comprobar la calidad del modelo final que ha sido generado.

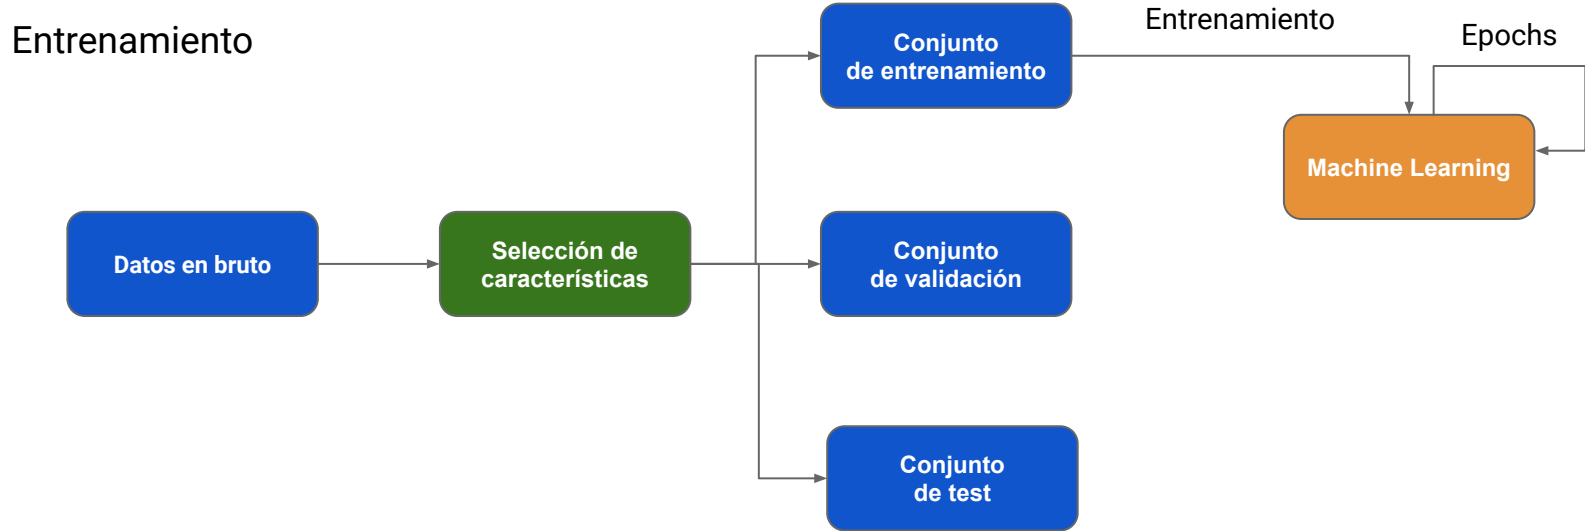
2. El proceso de aprendizaje

Entrenamiento



Algoritmo: Es el método de aprendizaje que se utilizar para construir el modelo de razonamiento.

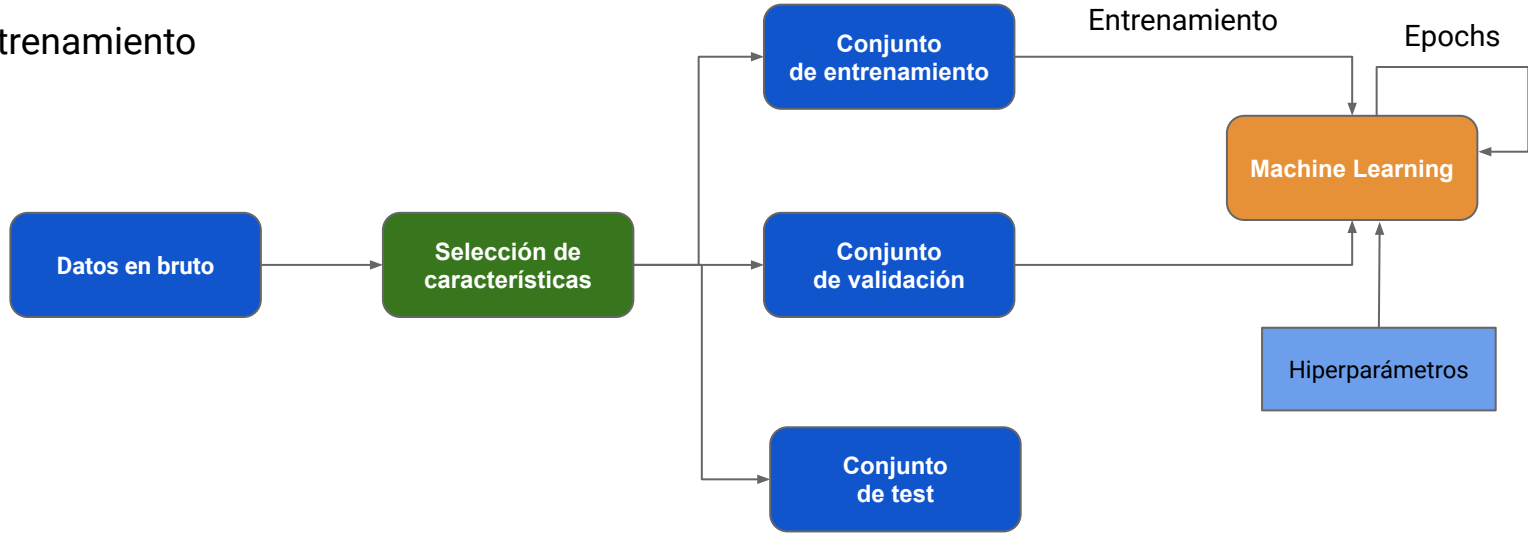
2. El proceso de aprendizaje



Épocas (epochs): Son el conjunto de iteraciones en las que se realiza el proceso de entrenamiento con el objetivo de construir el mejor modelo.

2. El proceso de aprendizaje

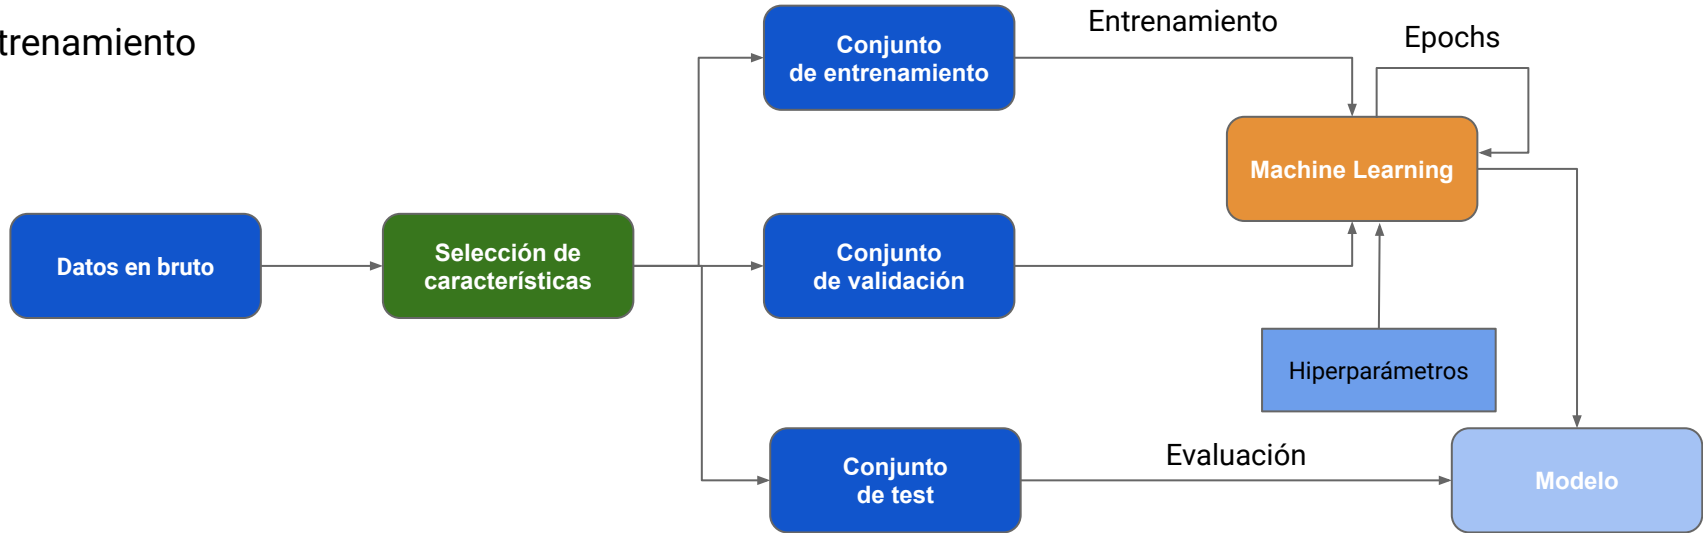
Entrenamiento



Hiperparámetros: Son un conjunto de parámetros referentes al algoritmo que permiten modificar el proceso de aprendizaje.

2. El proceso de aprendizaje

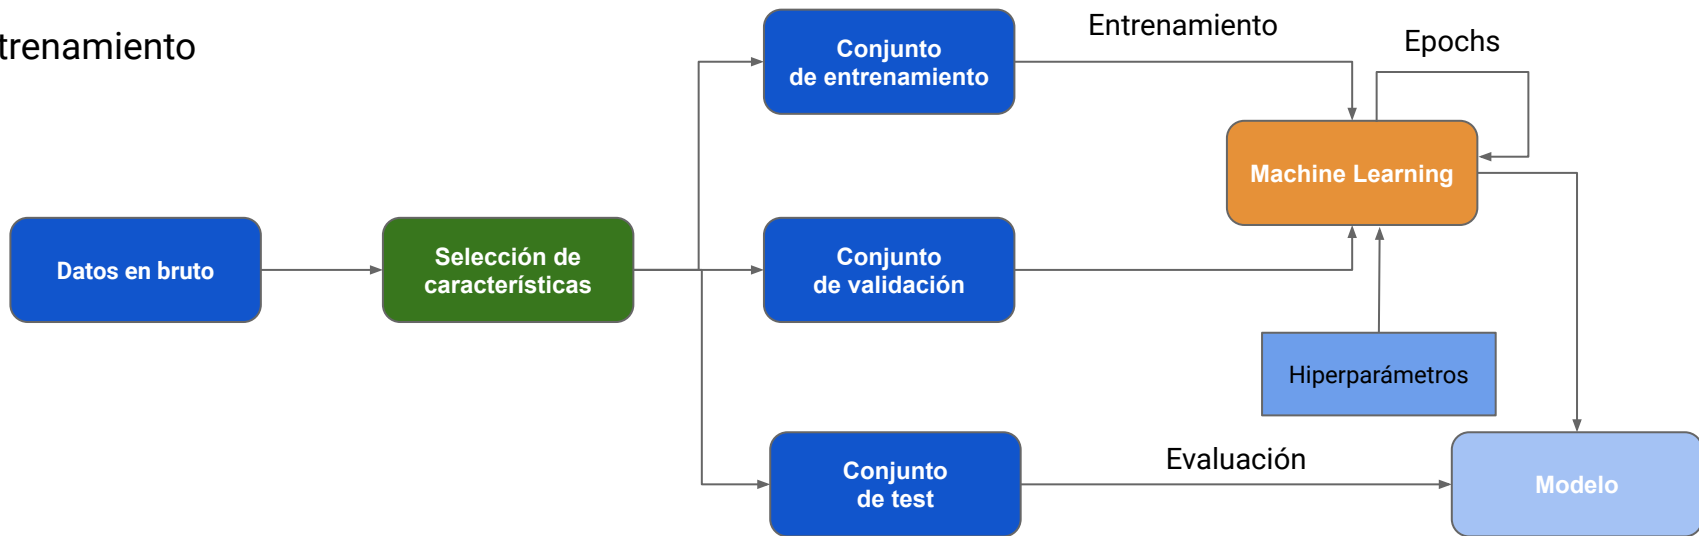
Entrenamiento




Modelo: Conjunto de reglas o patrones inferidos a partir del conjunto de entrenamiento con el objetivo de predecir, inferir o definir la agrupación de una instancia.

2. El proceso de aprendizaje

Entrenamiento



Inferencia




2. Redes de Neuronas




2. Redes de neuronas

Shallow Neural Network




Deep Neural Network




La **diferencia** que existe entre una red “shallow” y una red “profunda” es el número de capas ocultas (amarillo). Es decir, una red de neuronas profundas es aquella que tiene múltiples capas ocultas

2. Redes de neuronas



2. Redes de neuronas



Sigmoid

$$\phi(z) = \frac{1}{1 + e^{-z}}$$

Hyperbolic Tangent

$$\phi(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

Rectified Linear

$$\phi(z) = \begin{cases} 0 & \text{if } z < 0 \\ z & \text{if } z \geq 0 \end{cases}$$

Radial Basis Function

$$\phi(z, c) = e^{-(c\|z-c\|)^2}$$


La función de activación se encarga de generar una salida a partir de un valor de entrada, normalmente el conjunto de valores de salida está determinado mediante un rango como (0,1) o (-1,1).

Función ReLU


La función ReLU (Rectified Linear Unit) transforma los valores de entrada anulando los valores negativos y manteniendo los positivos tal y como entran.

- Función de tipo Sparse, es decir sólo se activan los positivos.
- No está acotada.
- Buen comportamiento con valores positivos (imágenes).
- Mal comportamiento con valores negativos (muerte de neuronas).

2. Redes de neuronas - Feed Forward



2. Redes de neuronas - Feed Forward



Pesos


$ihWeights[][]$

0.01	0.02	0.03	0.04
0.05	0.06	0.07	0.08
0.09	0.10	0.11	0.12

$hoWeights[][]$

0.13	0.14
0.15	0.16
0.17	0.18
0.19	0.20

2. Redes de neuronas - Feed Forward



Pesos


$ihWeights[][]$

0.01	0.02	0.03	0.04
0.05	0.06	0.07	0.08
0.09	0.10	0.11	0.12

$hoWeights[][]$

0.13	0.14
0.15	0.16
0.17	0.18
0.19	0.20

2. Redes de neuronas - Feed Forward



Pesos

$ihWeights[][]$

0.01	0.02	0.03	0.04
0.05	0.06	0.07	0.08
0.09	0.10	0.11	0.12


func(Op + Bias)

$hoWeights[][]$

0.13	0.14
0.15	0.16
0.17	0.18
0.19	0.20

Bias: Parámetro adicional utilizado en las redes de neuronas para ajustar el bias (Ayuda al entrenamiento)

2. Redes de neuronas - Feed Forward



Pesos


$ihWeights[][]$

0.01	0.02	0.03	0.04
0.05	0.06	0.07	0.08
0.09	0.10	0.11	0.12

$hoWeights[][]$

0.13	0.14
0.15	0.16
0.17	0.18
0.19	0.20

2. Redes de neuronas - Feed Forward



Pesos


$ihWeights[][]$

0.01	0.02	0.03	0.04
0.05	0.06	0.07	0.08
0.09	0.10	0.11	0.12

$hoWeights[][]$

0.13	0.14
0.15	0.16
0.17	0.18
0.19	0.20

2. Redes de neuronas - Feed Forward



Pesos


$ihWeights[][]$

0.01	0.02	0.03	0.04
0.05	0.06	0.07	0.08
0.09	0.10	0.11	0.12

$hoWeights[][]$


0.13	0.14
0.15	0.16
0.17	0.18
0.19	0.20

2. Redes de neuronas



2. Redes de neuronas - Feed Forward vs Convolucionales

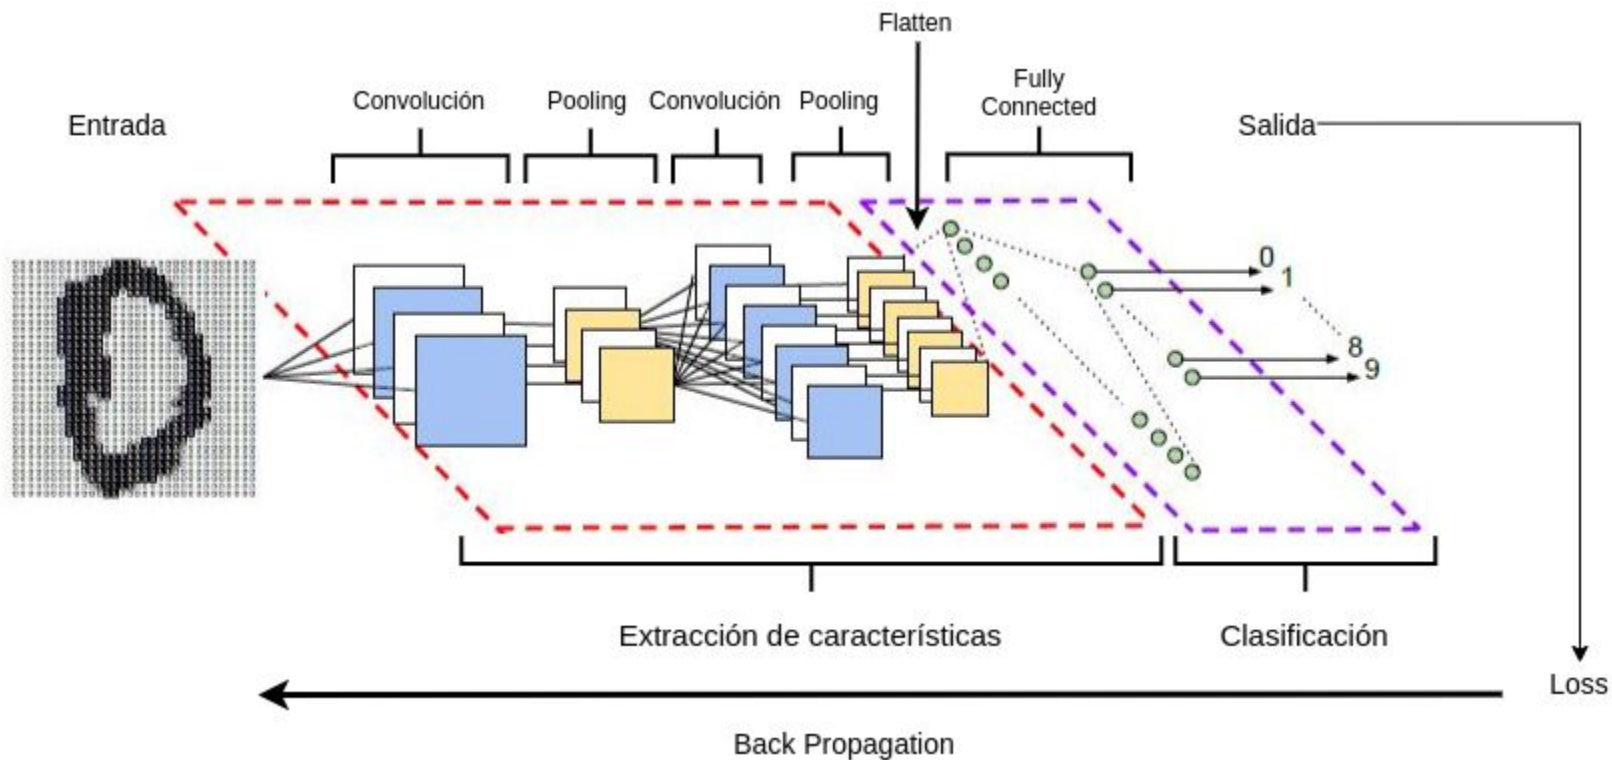
	Red Feed Forward (FFNN)
Capa Entrada	Secuencia de características
Capas Ocultas	Capas totalmente conectadas
Capa Salida	Elementos a predecir
Aprendizaje	Supervisado
Interconexiones	Total entre capas
Backpropagation	Aprendizaje de los pesos



2. Redes de neuronas - Feed Forward vs Convolucionales

	Red Feed Forward (FFNN)	Red Convocional (CNN)
Capa Entrada	Secuencia de características	Píxeles de una imagen
Capas Ocultas	Capas totalmente conectadas	Diferentes tipos de capas: <ul style="list-style-type: none">• Convolucionales• Subsampling• Fully-connected
Capa Salida	Elementos a predecir	Elementos a predecir
Aprendizaje	Supervisado	Supervisado
Interconexiones	Total entre capas	Parcial entre capas
Backpropagation	Aprendizaje de los pesos	Aprendizaje de los filtros

2. Redes de neuronas - Convolucionales



2. Redes de neuronas - Convolucionales

Las redes de neuronas **prealimentadas** son redes donde la información se mueve en una única dirección.

Información



2. Redes de neuronas - Convolucionales

Las redes de neuronas **prealimentadas** son redes donde la información se mueve en una única dirección.

Información



Back propagation

2. Redes de neuronas - Convolucionales

Las redes de neuronas **prealimentadas** son redes donde la información se mueve en una única dirección.

Información



1. Comparación de la salida esperada con la salida obtenida => salida esperada - salida obtenida = error

Back propagation

2. Redes de neuronas - Convolucionales

Las redes de neuronas **prealimentadas** son redes donde la información se mueve en una única dirección.

Información



1. Comparación de la salida esperada con la salida obtenida => salida esperada - salida obtenida = error
2. Error se propaga hacia atrás mediante (retroalimentación) para recalcular los pesos de las conexiones

Back propagation

2. Redes de neuronas - Convolucionales

Las redes de neuronas **prealimentadas** son redes donde la información se mueve en una única dirección.

Información



1. Comparación de la salida esperada con la salida obtenida \Rightarrow salida esperada - salida obtenida = error
2. Error se propaga hacia atrás mediante (retroalimentación) para recalcular los pesos de las conexiones
3. Descenso de gradiente (optimización): Derivada de la función de error con respecto a los pesos

Back propagation

2. Redes de neuronas - Convolucionales (Feed Forward)

Las redes de neuronas **prealimentadas** son redes donde la información se mueve en una única dirección.

Información



1. Comparación de la salida esperada con la salida obtenida => salida esperada - salida obtenida = error
2. Error se propaga hacia atrás mediante (retroalimentación) para recalcular los pesos de las conexiones
3. Descenso de gradiente (optimización): Derivada de la función de error con respecto a los pesos

Back propagation

3. TensorFlow




3. Redes de neuronas - TensorFlow


Tensor

+

Flow



N-dimensional array



Conjunto de operaciones

3. Redes de neuronas - TensorFlow

La información se representa mediante tres tipos de **contenedores de información**, que deben ser definidos a priori, con el objetivo de que sean incluidos en el grafo de operaciones.


Tipo	Formato	Función	Ejemplo
Constante	Constante	tf.constant	tf.constant([None, 800, 460, 4])
Variable	Variable	tf.variable	tf.Variable(tf.random_normal([size, size, channels, filters], stddev=0.01), name='Layer_1_weights')
Placeholder	Variable (in/out)	tf.placeholder	tf.placeholder('float32', input, name='train_X')

4. Capas y funciones



4. Capas y funciones - Capa convolucional

Las capas convolucionales se utilizan para la extracción de características mediante la aplicación de operaciones (productos y sumas) entre matrices. Estas operaciones se realizan mediante un filtro (kernel) cuadrado.



`Conv2D(32, kernel_size=3, activation='relu', input_shape=(28,28,1))`

4. Capas y funciones - Capa Pooling


Las capas **pooling** se utilizan para la realización de una reducción de información con el objetivo de centrarse en cierta información dependiendo de la operación a realizar. Esta reducción se realiza mediante la utilización de funciones como el promedio, el máximo o el mínimo.

1	0	2	3
4	6	6	8
3	1	1	0
1	7	2	4

Max-Pooling (2x2)




6	8
7	4



Filtro: 3X3

`MaxPooling2D(pool_size=k)`

4. Capas y funciones - Flatten




La capa de **aplanamiento**(flatten) es uno de los componentes esenciales de las redes de neuronas convolucionales..

Su funcionamiento consiste en aplicar una transformación lineal entre dos capas que realiza un aplanamiento de la información. Es decir se convierte una estructura bidimensional (matriz) a una estructura unidimensional (vector).

De manera que si una capa de tipo flatten se aplica sobre una capa de tamaño 2x2 el resultados será una capa de tamaño 4.

Flatten()

4. Capas y funciones - Fully Connected



La capa **completamente conectada** (fully-connected) es uno de los componentes esenciales de las redes de neuronas.

Su funcionamiento consiste en conectar cada neurona de una capa con cada neurona de la siguiente capa.


`Dense(10, activation='softmax')`

5. Itinerarios del taller





5. Itinerarios del taller

El taller tiene un conjunto de 6 ejercicios cuya realización depende de la tecnología que utilice el estudiante para la realización del taller. Existen dos itinerarios diferentes cada uno de ellos basado en una tecnología de despliegue de los cuadernos.




5. Itinerarios del taller

El camino de la dockerización



5. Itinerarios del taller

El camino de la colaboración en el cloud



Itinerario recomendado

¡Muchas Gracias!

¿Preguntas?
@moisipm



6. Capas con TensorFlow



4. Capas y funciones - Capa convolucional


Convolución

+

Bias

+

Función de activación



4. Capas y funciones - Capa convolucional

Convolución


+

Bias

+

Función de activación

```
conv_out = tf.nn.conv2d(input, weights, strides=[1, stride, stride, 1], padding='VALID', name='layer_1_conv')
```



4. Capas y funciones - Capa convolucional

Convolución

+

Bias

+

Función de activación


Capa anterior

Modo de aplicación del filtro

```
conv_out = tf.nn.conv2d(input, weights, strides=[1, stride, stride, 1], padding='VALID', name='layer_1_conv')
```

Pesos

Distancia entre la que se aplican los filtros



4. Capas y funciones - Capa convolucional

Convolución

+

Bias

+

Función de activación

Capa anterior


```
conv_out = tf.nn.conv2d(input, weights, strides=[1, stride, stride, 1], padding='VALID', name='layer_1_conv')
```

Pesos

Modo de aplicación del filtro

Distancia entre la que se aplican los filtros

```
bias_out= tf.add(conv_out, bias)
```



4. Capas y funciones - Capa convolucional

Convolución

+

Bias

+

Función de activación

Capa anterior

```
conv_out = tf.nn.conv2d(input, weights, strides=[1, stride, stride, 1], padding='VALID', name='layer_1_conv')
```


Pesos

Modo de aplicación del filtro

Distancia entre la que se aplican los filtros

```
bias_out= tf.add(conv_out, bias)
```

bias



4. Capas y funciones - Capa convolucional

Convolución

+

Bias

+

Función de activación

Capa anterior

```
conv_out = tf.nn.conv2d(input, weights, strides=[1, stride, stride, 1], padding='VALID', name='layer_1_conv')
```

Pesos


Modo de aplicación del filtro

Distancia entre la que se aplican los filtros

```
bias_out = tf.add(conv_out, bias)
```


bias

```
output = tf.nn.relu(bias_out, name='Layer_1_activation_fun')
```




4. Capas y funciones - Capa Pooling

Las capas **pooling** se utilizan para la realización de una reducción de información con el objetivo de centrarse en cierta información dependiendo de la operación a realizar. Esta reducción se realiza mediante la utilización de funciones como el promedio, el máximo o el mínimo.



```
pool_out = tf.nn.max_pool(input, ksize=[1, k, k, 1], strides=[1, k, k, 1], padding='SAME')
```

4. Capas y funciones - Flatten + Fully Connected



La capa **completamente conectada** (fully-connected) es uno de los componentes esenciales de las redes convolucionales.

Su funcionamiento consiste en realizar una operación de “flattens” que es utilizada como salida de la red o entrada de la siguiente capa. La operación de “flatten” consiste en realizar un **aplanamiento** convirtiendo la información obtenida en un vector de **una dimensión**.

```
fully_out = tf.add(tf.matmul(input, weights[len(layers)-1]), biases[len(layers)-1])
```